

Visualització de dades

Part I: Selecció del conjunt de dades

Aula 2

Ariadna Quingles Lamarca

M2.959

Part I: Selecció del conjunt de dades

Anàlisi visual dels costos i perfils d'hospitalització a Nova York a partir del conjunt de dades SPARCS

Aquesta activitat, primera part de la pràctica final, consisteix en la selecció d'un conjunt de dades del nostre interès que serà usat en el projecte de creació de la visualització de dades, d'acord amb uns criteris establerts, i la definició dels objectius que es volen assolir amb el mateix.

Tema: Costos i perfils d'hospitalització

Àmbit: Sanitat i desigualtats

Tipus de dades: Clíniques, demogràfiques i econòmiques

Font: New York State Department of Health, portal Health Data NY.

Enllaç (2024): <https://health.data.ny.gov/Health/Hospital-Inpatient-Discharges-SPARCS-De-Identified/sf4k-39ay>

Abast: Nova York; 2024

Mida: gran (milions). Diversos treballs reporten >2,3 milions de registres per un any de SPARCS.

1. Justificació de la selecció

Per a aquesta pràctica he seleccionat el conjunt de dades **SPARCS – Hospital Inpatient Discharges (de-identified)**, publicat pel **New York State Department of Health** a través de **Health Data NY**. SPARCS és un sistema de dades sanitàries de tipus all-payer que recull informació a nivell de pacient sobre característiques del pacient, diagnòstics, tractaments, serveis i càrrecs hospitalaris, i va ser creat inicialment per recopilar informació sobre altes hospitalàries.

He triat aquest conjunt per motius tant **personals com acadèmics**. Des d'una perspectiva de ciència de dades, em sembla especialment interessant perquè combina variables clíniques, demogràfiques, territorials i econòmiques dins d'un mateix conjunt. Això permet anar més enllà d'una visualització descriptiva simple i plantejar preguntes rellevants sobre el cost sanitari, la durada de l'estada, la severitat clínica i les possibles desigualtats entre grups de pacients. D'altra banda, treballo a l'hospital de la Creu i Sant Pau en un departament de gestió de recursos i tenia curiositat de poder veure els resultats d'aquest tipus d'estudi a l'altra banda del món en un lloc com Estats Units.

2. Rellevància del conjunt de dades

El conjunt és rellevant per diversos motius.

En primer lloc, tracta un tema de gran impacte social: **l'ús dels recursos hospitalaris i els costos associats a l'atenció sanitària**. Aquest és un tema d'interès tant per als professionals de salut i gestors sanitaris com per a la ciutadania, ja que permet entendre millor com es

distribueixen els costos hospitalaris i quins factors s'hi associen. SPARCS s'utilitza, entre altres finalitats, per a recerca, planificació sanitària, assignació de recursos i avaluació de polítiques públiques.

En segon lloc, són dades **actuals i actualitzades**. La sèrie d'hospitalitzacions inpatient està disponible des de **1982 fins a l'actualitat**, i per a 2024 el sistema reporta dades completes amb publicació recent.

En tercer lloc, el conjunt té una clara **dimensió social i de desigualtat**. Inclou variables com **gènere, grup d'edat, raça, ètnia, zona hospitalària, codi postal agregat, tipus d'ingrés, tipus de pagament i diagnòstic**, de manera que permet estudiar diferències entre col·lectius. Això fa possible incorporar perspectiva de gènere i també una lectura sobre desigualtat territorial o socioeconòmica, encara que cal fer-ho amb prudència perquè es tracta de dades administratives desidentificades.

Aquesta orientació és coherent amb la teoria de l'assignatura, segons la qual la visualització ha de servir per comunicar, explorar, contextualitzar i detectar patrons o anomalies.

3. Complexitat del conjunt de dades

Aquest conjunt de dades compleix el criteri de complexitat.

SPARCS és un dataset **multivariable i heterogeni**, amb dades categòriques i quantitatives, i amb suficient riquesa per extreure coneixement útil. La documentació del fitxer desidentificat mostra variables com ara: regió sanitària, comtat de l'hospital, hospital, grup d'edat, gènere, raça, ètnia, estada, tipus d'admissió, disposició del pacient a l'alta, any d'alta, categories diagnòstiques i de procediment, severitat, risc de mortalitat, tipologies de pagament, pes neonatal, indicador de pas per urgències, càrrecs totals i costos totals.

A nivell de mida, el conjunt complet és **molt gran**: només l'any **2024** inclou **2.197.128 altes hospitalàries inpatient** a escala estatal. Això supera clarament la recomanació ideal d'unes poques milers de files, de manera que, per fer-lo viable per a la pràctica, proposo treballar amb una **selecció o agregació** del conjunt.

Per tant, la meua proposta és treballar amb una de les opcions següents:

- una mostra d'un únic any, preferiblement **2024**,
- o bé una agregació per **hospital, diagnòstic, grup d'edat i gènere**,
- o bé un subconjunt centrat en un grup clínic concret.

D'aquesta manera es manté la riquesa del dataset, però amb una mida manejable per a la visualització final. Un cop hagi treballat més les dades decidiré quina selecció fer.

4. Originalitat de la proposta

Considero que aquesta proposta és original per diversos motius.

En primer lloc, posa el focus en una qüestió mèdica i econòmica menys recurrent però molt rellevant: **què explica el cost d'una hospitalització i com es distribueix entre diferents perfils de pacients.**

En segon lloc, no plantejo una simple representació descriptiva del conjunt, sinó un projecte que pot ser **enriquit** amb mètriques derivades, com ara:

- cost per dia d'estada,
- cost mitjà per grup diagnòstic,
- diferència entre càrrecs i costos,
- perfils de major risc clínic i major consum de recursos.

Aquest tipus de treball encaixa amb la idea que visualitzar dades és un procés de transformació i refinament, no només d'ús directe del dataset. També és coherent amb la idea que la preparació de dades és una fase crucial del procés i que les dades s'han de netejar, estructurar i enriquir abans de visualitzar-les.

En tercer lloc, és un conjunt amb molt potencial narratiu. Permet explicar històries sobre eficiència hospitalària, perfils clínics, desigualtats i patrons de cost, és a dir, qüestions que van més enllà de la simple descripció estadística.

5. Qüestions i objectius de la visualització

Seguint les recomanacions del material docent, la visualització ha de començar amb preguntes concretes. L'objectiu general del projecte serà:

Explorar i comunicar quins factors clínics, demogràfics i territorials s'associen a una major càrrega econòmica en les hospitalitzacions inpatient a Nova York.

A partir d'aquest objectiu general, plantejo les preguntes següents:

1. **Quins grups diagnòstics generen majors costos i càrrecs hospitalaris?**
2. **Com varien els costos segons el grup d'edat, el gènere i el tipus d'admissió?**
3. **Hi ha diferències entre hospitals o àrees sanitàries en cost i durada d'estada?**
4. **Com es relacionen la severitat clínica, el risc de mortalitat i el cost total?**
5. **Quins perfils de pacient concentren més consum de recursos hospitalaris?**

Aquestes preguntes són adequades perquè el dataset conté variables suficients per respondre-les, i alhora permeten construir una narrativa visual clara.

6. Diccionari inicial de variables

A continuació es presenta una selecció inicial de variables rellevants i la seva classificació com a **fet** o **dimensió**.

Dimensions

- **Health Service Area:** regió sanitària on es troba l'hospital. Dimensió geogràfica.
- **Hospital County:** comtat de l'hospital. Dimensió geogràfica.
- **Facility Name / Facility ID:** hospital o centre on es presta el servei. Dimensió institucional.
- **Age Group:** grup d'edat del pacient. Dimensió demogràfica.
- **Gender:** gènere del pacient. Dimensió demogràfica.
- **Race:** raça del pacient. Dimensió demogràfica/social.
- **Ethnicity:** ètnia del pacient. Dimensió demogràfica/social.
- **Zip Code – 3 digits:** àrea territorial agregada del pacient. Dimensió geogràfica.
- **Type of Admission:** tipus d'ingrés, com urgent, elective o emergency. Dimensió assistencial.
- **Admit Day of Week / Discharge Day of Week:** dia de la setmana de l'ingrés o alta. Dimensió temporal.
- **Discharge Year:** any de l'alta. Dimensió temporal.
- **CCS Diagnosis Description:** categoria diagnòstica principal. Dimensió clínica.
- **CCS Procedure Description:** categoria de procediment. Dimensió clínica.
- **APR DRG Description:** grup relacionat amb el diagnòstic. Dimensió clínica.
- **APR Severity of Illness Description:** severitat del cas. Dimensió clínica ordinal.
- **APR Risk of Mortality:** risc de mortalitat associat. Dimensió clínica ordinal.
- **Payment Typology 1/2/3:** tipologia de pagament. Dimensió econòmica/administrativa.
- **Emergency Department Indicator:** indica si el cas va passar per urgències. Dimensió assistencial binària.

Fets o mesures

- **Length of Stay:** nombre de dies d'estada. Fet quantitatiu.
- **Total Charges:** càrrecs totals de l'hospitalització. Fet quantitatiu econòmic.
- **Total Costs:** cost total estimat de l'hospitalització. Fet quantitatiu econòmic.
- **Birth Weight:** pes neonatal, quan aplica. Fet quantitatiu clínic.

La documentació oficial del fitxer desidentificat confirma aquestes variables i les seves definicions bàsiques.

7. Viabilitat i estratègia de treball

Des d'un punt de vista de ciència de dades, el conjunt és **molt potent però massa gran si es treballa complet**. Per això, la meua proposta metodològica és:

1. descarregar el fitxer **inpatient de 2024**,
2. fer una fase de **neteja i inspecció**,
3. seleccionar les variables més rellevants,
4. crear un subconjunt o una agregació de mida manejable,
5. construir una narrativa visual centrada en costos, severitat i perfils de pacient.

Caldrà tractar valors absents, outliers, errors de format i categories inconsistents, i treballar amb dades en format tabular i tidy quan sigui possible.

També la idea és desenvolupar la visualització com a procés iteratiu: es parteix d'unes preguntes inicials, s'exploren les dades, s'afinen els objectius i es decideix quina representació és la més adequada.

8. Consideracions ètiques

Tot i que SPARCS és un conjunt **desidentificat**, continua sent un dataset sanitari sensible. La mateixa documentació del sistema diferencia entre fitxers públics desidentificats i versions limitades o identificables, que requereixen aprovació específica.

Per tant, en la visualització final evitaré:

- interpretacions estigmatitzadores sobre raça, ètnia o gènere,
- conclusions causals no justificades.

A més, les guies d'open data de Nova York alerten sobre riscos de reidentificació indirecta o **mosaic effect**, fins i tot quan les dades són obertes.

9. Conclusió

Considero que **SPARCS – Hospital Inpatient Discharges (de-identified)** és un conjunt de dades molt adequat per al projecte final de visualització de dades. Té una alta rellevància social, combina dimensions mèdiques, demogràfiques i econòmiques, ofereix prou complexitat per a un treball de ciència de dades i permet formular preguntes rellevants i originals sobre costos hospitalaris i desigualtats en salut.

La principal dificultat és la seva mida, però això es pot resoldre amb una estratègia de mostreig o agregació. Lluny de ser un inconvenient, aquesta necessitat reforça la part metodològica del projecte, ja que obliga a aplicar criteris de preparació, selecció i transformació de dades abans de visualitzar-les.

Per aquests motius, considero que aquest conjunt de dades és una elecció sòlida, coherent i amb molt potencial narratiu per a la segona part de la pràctica.

10. Fonts i referències

- Health Data NY. SPARCS Hospital Inpatient Discharges (de-identified).
- New York State Department of Health / SPARCS Support. What is SPARCS and why was it established?
- New York State Department of Health / SPARCS Support. What data years are currently available in SPARCS?
- SPARCS de-identified data dictionary.

- UOC. Bones pràctiques en visualització de dades.
- UOC. Guia de lectures en l'àmbit de la visualització de dades.
- UOC. Preparació de les dades.